

多模态仇恨言论检测：从特征融合判别到大模型解释推理范式的转变

2026 年 7 月 30 日

摘要

关键词：

1 引言

随着社交媒体平台的爆发式增长，多模态仇恨言论（尤其是仇恨模因，Hateful Memes）人工审核因效率低下、成本高昂且容易对审核员造成心理创伤，已难以应对海量多模态数据的实时监管需求。因此，如何利用人工智能技术实现自动化、鲁棒的多模态仇恨模因检测，已成为自然语言处理（NLP）与计算机视觉（CV）交叉领域的前沿研究课题。

仇恨模因检测（Hateful Meme Detection, HMD）多维度复杂性：(1) 语义隐晦性：仇恨意图往往隐藏在讽刺或冷幽默中，单一模态可能完全无害；(2) 模态交互冲突：模因的真意通常源于图文之间的语义鸿沟或关联，而非简单的表征叠加；(3) 社会语境依赖性：判定过程高度依赖对特定文化、历史背景或社会群体隐喻的深层理解。这种特性使得 HMD 研究正经历从基础的“模式映射”向深层“语义推理”的范式演进。

为推动该领域发展，学界开展了诸多系统性梳理。传统的 HMD 研究主要聚焦于特征融合与二分类判定，即通过物理映射将多模态特征对齐并赋予“仇恨/非仇恨”的二元标签。这种基于黑盒表征拟合的范式难以揭示判别背后的逻辑，且在处理高冲突难样本时准确率受限。随着大规模多模态模型（LMMs）仇恨模因理解，强调决策的可解释性与逻辑溯源。

然而，现有的 HMD 领域综述尚未能充分反映这一重要转变：早期的综述多聚焦于纯文本检测；早期的多模态综述侧重于手工特征工程或深度学习的初步融合机制，缺乏对开放环境下复杂语义理解的系统阐述；即便是触及大模型应用的最新研究，也往往忽略了模型如何从“分类器”向具备社会感知能力的“推理者”转变的技术演进路径。现有工作普遍缺乏对推理类任务（如解释生成、智能体博弈）的深度剖析。因此，本文聚焦于大模型驱动的推理增强范式，对近年 HMD 领域的前沿进展进行了系统阐述。本文的主要贡献如下：

(1) 阐释多模态仇恨分析从“判别”到“推理”的范式跃迁机理。本文构建了感知判别与逻辑推理的概念框架，明确了模型在隐含语义识别、社会常识对齐及因果逻辑建构方面的具体要求，揭示了 HMD 研究从“表征判别”向“大模型解释推理”演进的内在逻辑。

(2) 构建大模型驱动的仇恨模因解释方法分类体系。本文提出基于提示与上下文语境的免训练范式、基于指令微调的策略对齐范式、以及基于智能体协同的多步反思范式，深入剖析其在语义一致性、知识增强与决策鲁棒性上的优势与局限。

(3) 建立面向解释性推理的评估基准与未来演进路线。本文梳理了含解释标注的数据集演进规律，划分了性能指标（AUC/Acc）、成本指标（Few-shot 效率）与理解指标（Rationale 质量），指出现有体系在衡量逻辑幻觉方面的不足，并提出了具备文化自适应能力的治理路线。**(引言示例，后续修改)**

2 仇恨言论检测与概念界定

在此处编写概念界定与任务定义。

- **概念界定**：明确仇恨言论 (Hate Speech) 的核心特征 (针对特定受保护群体的攻击性), 并将其与冒犯性言论 (Offensive)、毒性言论 (Toxic) 及网络暴力 (Cyberbullying) 进行区分。
- **呈现形态分类**：介绍显性仇恨 (Explicit)、隐性暗喻 (Implicit) 以及跨模态讽刺 (Cross-Modal Irony) 的表征差异。

3 基于小模型的方法

小模型范式下按照仇恨检测所依赖的核心信息来源与建模侧重点, 从内到外划分为「基于内容的方法」与「外部知识增强方法」两大类: 前者仅依靠多模态内容本身完成判别, 后者引入内容之外的补充信息以弥补语义鸿沟。

3.1 基于内容的方法

3.1.1 单模态基础：传统特征工程与机器学习

早期多模态仇恨言论检测研究主要聚焦于手工特征与统计模式的协同, 旨在通过先验领域知识提取判别性特征来驱动浅层分类器。该阶段的研究重心在于如何将非结构化的图文信息转化为机器可理解的结构化特征向量。

在文本特征提取方面, 研究者普遍采用词袋模型 (Bag-of-Words, BOW)、N-gram 语法特征以及词频-逆文档频率 (TF-IDF) 权重向量来捕捉词汇分布特征。为了进一步挖掘语言中的攻击性线索, 情感词典 (Lexicons)、词性标注 (POS Tags) 以及主题模型 (如 LDA) 被广泛引入, 用以弥补纯统计特征在句法关联和情感极性感知上的不足。

在视觉特征提取方面, 早期方法多依赖于底层视觉描述符, 通过手工提取 SIFT 特征、颜色直方图或图像纹理特征等来表征图片内容。然而, 此类粗粒度的视觉表征往往难以捕捉到模因中极具隐喻色彩的文化符号和微妙的图像语义。

在分类决策层面, 研究者通常将提取的多模态手工特征进行简单拼接, 并输入至传统机器学习模型中进行判别。支持向量机 (SVM) 凭借处理高维稀疏特征的优势, 成为这一阶段最为流行的检测模型; 随机森林 (Random Forest)、朴素贝叶斯 (Naive Bayes) 以及逻辑回归 (Logistic Regression) 也常被作为基准模型用于显性仇恨言论的判定。

尽管传统范式在处理显性辱骂词汇时具备较好的解释性与执行效率, 但其本质上仍属于“强感知、无推理”的表层匹配, 高度依赖领域专家的人工经验且泛化能力薄弱, 在面对复杂语义歧义、文化隐喻以及快速演进的隐性仇恨时容易陷入判别瓶颈——这也为后续深度多模态融合方法的兴起埋下伏笔。

3.1.2 多模态融合方法

随着深度学习技术的成熟，研究重心从简单的特征叠加转向了对跨模态交互机制的深度挖掘，融合能力呈现出从静态拼接到自适应加权再到结构化推理的演进脉络。

简单融合（早期融合） 早期融合通常在特征提取阶段之后，通过简单的向量拼接（Concatenation）实现图文信息的初步聚合。代表性工作利用 ResNet 提取图像特征，并与 BERT 输出的文本嵌入直接拼接，随后输入全连接层进行分类；部分研究通过拼接图像全局特征与文本特征，在标杆数据集上建立了基础基准。然而此类方法本质上仍属于“特征堆叠”，缺乏对模态间语义冲突或互补关系的显式建模，容易在处理图文反讽（如图像良性但文字仇恨）时产生感知偏离。

注意力融合（中期融合） 为克服早期融合的局限，研究者引入了以 Transformer 为核心的中期融合架构，利用交叉注意力（Cross-Attention）或联合注意力机制，强制模型在统一的语义空间内审视图文关联。代表性模型如 VisualBERT、UNITER 和 OSCAR，通过将图像区域（Region）作为特殊的“视觉词元”，与文本序列一同输入 Transformer 编码器，实现了模态间的深度协同。Wu 等人提出的跨模态注意力掩码（CAM）架构，通过掩码机制显式过滤无关噪声，聚焦于诱发仇恨的关键图文对。

动态融合 M2KE 框架引入了门控融合（Gated Fusion）机制，利用信息熵正则化动态调整模型对图像与文本的关注权重，有效缓解了模型对单一模态的过度依赖问题。这种“动态对齐”策略相较静态的注意力融合更进一步，显著提升了模型对隐性仇恨语义的捕捉能力。

晚期融合（决策级融合） 晚期融合在不同模态的分类器输出端进行聚合，通常利用独立的单模态编码器分别对图像和文本建模，最后通过决策向量拼接或加权投票产生最终判定。该策略能够最大限度保留各模态的独立特性，但在处理需要深层背景知识支撑的复杂模因时，往往由于缺乏早期语义对齐而难以识别跨模态涌现的攻击意图。

3.1.3 多模态对比学习方法

为缓解多模态数据间的语义鸿沟，研究重心正由传统的表层特征拼接（融合方法）转向基于对比学习的连续空间对齐——二者形成互补：融合方法负责最终决策，对比学习负责表征正则与跨域泛化能力。该范式旨在通过将图像与文本特征映射至统一的语义表征空间，捕捉跨模态之间的深层语义关联，从而解决单模态信息在处理隐性仇恨时的局限性。

这类研究的典型工作由 Mei 等人完成，他们针对仇恨言论检测中极具挑战性的混淆样本问题——即图像或文本内容高度相似但语义完全相反的样本——提出了检索引导

的对比学习 (RGCL) 框架。RGCL 放弃了早期的特征粗暴拼接策略, 转而利用 CLIP 等大规模视觉-语言预训练模型作为基础编码器, 并引入了动态样本检索机制: 利用 Faiss 向量索引在训练集内动态挖掘语义相似且类别相同的样本, 以及视觉或文本相似但类别相反的样本。通过引入对比损失函数, RGCL 强制模型在嵌入空间中拉近真实正样本与“伪金标准”之间的距离, 同时推开具有欺骗性的硬负样本, 使得模型能够学习到具备仇恨感知的跨模态联合表征, 显著增强了对模因中微妙语义差异的敏感度。

此外, 这类方法具有极强的普适性, 能够显著提升包括 OpenCLIP、AltCLIP 以及 ALIGN 在内的多种视觉-语言编码器在 HSD 任务中的判别能力, 在 HatefulMememes 和 HarMeme 等标杆数据集上均取得了超越传统监督微调的效果。

3.2 外部知识增强方法

内容法难以覆盖隐式、隐晦、文化特定型仇恨, 这类方法通过引入内容之外的补充信息来拓展模型的认知边界。需要说明的是, 此处所述方法均以小模型/判别式架构为核心, 尚未依赖 LLM 的通用推理能力, 因此与下文大语言模型参与的方法中的知识增强路径存在本质区别。

3.2.1 仇恨知识库增强方法

Huang 等人提出 Looking Outward 策略, 将检索到的相似已标注模因的标签作为显式辅助信号, 为模型判别提供先验偏好。这类方法本质上是构建了一个隐式的“已知仇恨案例库”, 通过案例检索而非模型内部推理来补充判别信号, 针对性提升了对已知仇恨表达模式的召回率。

3.2.2 常识与文化知识增强方法

Lu 等人提出的 M2KE 框架强调了背景知识 (Rationales) 的重要性: 该框架不仅提取实体信息和图像描述, 还引入了自适应知识交互机制, 利用信息熵正则化动态平衡模型对原始图文与外部解释的关注度。这种机制有效防止了模型对不可信外部知识的过度依赖, 确保了外部证据与原始模因语义的深度对齐, 为理解隐喻、圈层黑话等隐式冒犯语义提供了背景支撑。

4 大语言模型驱动的方法

LLM/MLLM 的引入使检测器从固定特征的判别式分类器, 转变为可理解隐式语义、可进行语境推理的智能体。按照 LLM 在检测流水线中的参与程度与核心功能角色, 划分为「大语言模型增强方法」(LLM 仅为辅助组件) 与「基于大语言模型的方法」(LLM/MLLM 直接作为检测主体) 两大类。

4.1 基于大语言模型的方法：通用架构

典型的 MLLM 驱动检测流水线 (Pipeline) 通常包含视觉/音频编码器、模态适配器 (Modality Adapter) 以及作为认知推理基座的 LLM 三部分：编码器负责提取原始模态特征，适配器将其映射至 LLM 可理解的语义空间，LLM 则承担最终的语境理解与逻辑推理职责。这一架构是本节下述「基于内部知识的方法」与「外部知识驱动方法」的共同技术底座。

4.1.1 基于内部知识的方法

该范式旨在不依赖外部实时检索的情况下，通过参数高效微调 (PEFT) 或精巧的提示工程 (Prompt Engineering)，激发多模态大语言模型内部蕴含的社会常识与逻辑推理能力。

在提示工程层面，研究者普遍采用思维链 (Chain-of-Thought, CoT) 引导模型进行分步推理，即先对模因的视觉元素和文本进行“内容解读”，再进行“隐喻分析”，从而捕捉到表层信息之外的隐性危害；也有研究探索了上下文学习 (In-Context Learning, ICL) 的潜力，通过从纯文本仇恨数据集中检索相似的少样本示例作为提示增强，证明了文本域的仇恨认知能力可以有效迁移至多模态任务中。

在模型微调层面，为平衡检测精度与计算成本，LoRA 与 QLoRA 成为主流技术栈。Mei 等人 (2025) 在 RA-HMD 的第一阶段训练中，利用 LoRA 对 LMM 的语言模型头 (LMH) 进行指令微调，强制模型在统一的连续特征空间内对齐物理事实 (视觉) 与因果逻辑 (文本)。这种“内生式”的推理范式显著提升了模型对特定受保护群体 (如宗教、性别) 被攻击时的感知灵敏度，有效缓解了传统模型在隐性仇恨检测上的性能崩塌。

多智能体协同与对抗辩论 值得注意的是，多智能体推理本质上仍是对 LLM 内部常识与逻辑能力的深度挖掘与结构化激发 (而非引入外部数据源)，因此归入内部知识方法的进阶分支。其代表了目前最前沿的认知推理方向，通过模拟人类社会的群体决策过程，以消除单模型决策的认知偏差：

- **司法对抗辩论**：Sun 等人 (2026) 提出的 ARCADE 框架创新性地模拟了法庭审判过程，包含控方 Agent (负责挖掘潜在风险、建立仇恨假设)、辩方 Agent (基于情境提供良性解释、识别讽刺或自嘲) 以及法官 Agent (审视辩论历史并裁决)。这种非对称的对抗辩论强制模型审视深层语义诱因，不仅大幅提升了隐性仇恨的检测准确率，还赋予了检测结果极强的证据追溯能力。
- **社会认知蒸馏**：Wang 等人 (2026) 提出的 SGoT-R1 引入“社会思维图” (Social Graph of Thought) 概念，先通过多智能体模拟不同背景 (如职业、评论习惯) 用户的多元观点，构建出体现“群体共识”的 SGoT 结构，再将其蒸馏至单一多模

态大模型中。这种范式将昂贵的在线多智能体运算转化为离线的认知增强，在维持推理深度的同时显著降低了工业级部署的推理时延。

4.1.2 引入外部知识方法

针对 MLLM 知识滞后以及难以理解特定亚文化“暗语” (Dog-whistles) 的问题，该分支通过检索增强生成 (Retrieval-Augmented Generation, RAG) 范式，在 LLM/MLLM 的推理过程中引入外部实时知识或相似案例来辅助决策，代表性方向如 Mei 等人的 RA-HMD 在指令微调对齐的基础上进一步结合检索机制，为隐性仇恨判定提供跨样本的证据支撑（区别于上一节仅依赖模型内生推理能力的路径）。

4.2 大语言模型增强方法

与上一节不同，此类方法中 LLM 仅作为辅助组件、不直接输出最终检测结果，核心价值是为下游专用（小模型）检测器补充语义理解能力，兼顾部署效率与语义理解深度。

4.2.1 跨模态语义增强方法

利用 MLLM 的视觉/音频编码器与模态适配器，将图片等非文本内容转化为结构化文本描述，补全视觉仇恨符号与梗图含义，缩小不同模态间的语义鸿沟，帮助下游判别式检测器（如小模型融合网络）更好地对齐多模态仇恨语义——这一角色与前述“通用架构”中的模态适配器功能相呼应，区别在于此处 LLM 的输出仅作为下游模型的输入特征，而非独立完成最终判定。

4.2.2 细粒度分析与可解释性增强方法

利用 LLM 的自然语言生成能力，为下游检测结果输出仇恨类型、仇恨目标、冒犯性片段定位、判断理由等细粒度信息，满足内容审核的合规要求与人工复核需求，弥补传统判别式小模型“黑盒输出、缺乏解释”的短板。

4.2.3 知识与语境增强处理方法

利用 LLM 对检索到的外部知识（如仇恨术语、文化背景、圈层黑话等）进行清洗、重排、改写，优化知识质量后再提供给下游检测流程，使外部知识更适配具体的仇恨检测任务，是对基于小模型的方法中外部知识增强方法的语义层面升级。

5 数据集与评估指标

5.1 数据集

梳理多模态仇恨言论领域的核心基准数据集（如 Facebook Hateful Memes, MAMI, HarMFul 等）。

表 1: 代表性多模态仇恨言论检测数据集汇总对比

数据集	年份	模态	规模	主要仇恨类型	核心挑战
Facebook Hateful Memes	2020	图 + 文	10,000	综合模因 (Memes)	良性翻转/图文讽刺
MAMI	2022	图 + 文	10,000	厌女言论 (Misogyny)	细粒度多标签分类
HarMFul	2022	图 + 文	3,000	疫情与政治相关	依赖外部背景知识

5.2 评估指标

除了常用的 Accuracy, Macro-F1, AUROC 外，重点介绍仇恨言论特有的评估指标：

- 目标群体公平性指标 (Target-Group Fairness)
- 再利用词/内群体词汇敏感度 (Reclaimed Slur Sensitivity)
- 解释忠实度指标 (Explanation Faithfulness)

5.3 性能对比与分析

横向与纵向对比小模型融合范式与大模型推理范式在标杆数据集上的效果与算力开销差异。

6 现有问题与未来方向

-
-
-
-

7 结论与展望

总结全文，强调从特征融合向大模型解释推理范式的转变，是实现安全、可信、可解释的互联网多模态内容治理的必然趋势。

参考文献

- [1] Douwe Kiela, Hamed Firooz, Aravind Mohan, Vedanuj Goswami, Amanpreet Singh, Patrick Ringschia, and Davide Testuggine. The hateful memes challenge: Detecting hate speech in multimodal memes. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 33, pages 2611–2624, 2020.
- [2] Elisabetta Fersini, Francesca Gasparini, Silvia Corchs, and Federico Alberto Pozzi. Semeval-2022 task 5: Multimodal misogyny identification. In *Proceedings of the 16th International Workshop on Semantic Evaluation (SemEval-2022)*, pages 543–562, 2022.
- [3] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, et al. Learning transferable visual models from natural language supervision. In *International Conference on Machine Learning (ICML)*, pages 8748–8763, 2021.
- [4] Haotian Liu, Chunyuan Li, Qingyang Wu, and Yong Jae Lee. Visual instruction tuning. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 36, pages 34892–34916, 2023.